COURSE RESEARCH PROPOSAL · REINFORCEMENT LEARNING

强化学习课题开题报告

基于工业真实日志的离线策略评估 (OPE) 与上下文 Bandit 算法实证研究

课题名称： 基于 OpenBandit 的离线策略评估实证研究

研究领域： 离线强化学习 (Offline RL) / 推荐系统

小组规模： 5 人研究小组

实验基准： ZOZOTOWN Open Bandit Pipeline (OBD & OBP)

预计周期： 4 周 (环境搭建 → 策略训练 → OPE 评测 → 答辩汇报)

预期交付： 开源实验代码仓、分析报告、学术演讲 Poster

一、 选题背景与研究意义

在工业级数字推荐平台与个性化广告分发系统中，直接将未经充分验证的强化学习策略部署至线上进行 A/B 测试面临极大挑战：不仅可能引起短期的商业转化率骤降，还极易损害用户体验。因此，**离线策略评估（Off-Policy Evaluation, OPE）**已成为策略上线前不可或缺的安全评估范式与核心学术课题。

然而，离线评估面临着深刻的统计挑战——**分布偏移（Distribution Shift）**与**反事实选择偏差（Selection Bias）**。历史日志数据是由旧的行为策略（π_b）生成的，而待评估的新决策策略（π_e）在相同用户状态下的动作概率分布大不相同。这导致常规的离线统计方法产生严重的系统性偏差或方差发散。

本项目依托日本时尚电商 ZOZOTOWN 开源的工业级数据集 **Open Bandit Dataset (OBD)**，该数据集罕见地同时记录了商业基线与全随机探索（Bernoulli TS）日志，为离线评估提供了可遇不可求的**真实线上回报标尺（Ground Truth）**。本课题将在此基准上系统评测主流 OPE 估计器的性能边界，为推荐算法工程落地提供坚实的量化选型支撑。

二、 国内外研究现状与技术痛点

当前学术界与工业界的主流离线评估方法大致可划分为三类：

- **直接法 (Direct Method, DM)：** 借助回归模型拟合状态-动作-奖励映射函数 $\hat{q}(x, a)$。其优势在于方差极低，但高度依赖模型拟合质量；若存在未观测混杂因素或模型欠拟合，将产生不可纠正的系统偏差。
- **重要性采样 (Inverse Propensity Scoring, IPS)：** 通过行为策略与评估策略的倾向得分比值 $\pi_e(a|x) / \pi_b(a|x)$ 进行样本加权，理论上具备无偏性。但在实际长尾或稀疏动作空间中，权重极易发散导致估计方差过大。自归一化技术（SNIPS）能在一定程度上缓解极值抖动。
- **双重稳健法 (Doubly Robust, DR)：** 将 DM 的预测作为基线，利用加权重要性残差项纠偏，理论上只要奖励拟合器或倾向得分模型中任意一个准确即可保持无偏，兼顾了低偏差与适度方差。

> **核心痛点问题**
>
> 在真实高维且高度稀疏的电商数据分布下，各类估计器在理论上的渐近性质是否依然稳定？当倾向性极端不均匀时，自归一化与裁剪阈值（Weight Clipping）该如何协同权衡“方差与偏差”？这是本项目重点切入的实证空白。

三、 研究目标与核心内容

1. 研究目标

1. **打通全流程工业级 OPE 实证闭环：** 从原始千万级日志解析开始，跑通 Contextual Bandit 策略学习与全套离线估计计算。
2. **建立多维度估计器度量基准：** 对齐随机探索日志测得的真实绝对收益，定量测量各估计器的均方误差（MSE）与策略排序相关度（Rank Correlation）。
3. **探究方差抑制机制的最优边界：** 针对 IPS 权重发散问题，深入探索自归一化（SNIPS）与分位数截断（Clipping）对评估精度的调节规律。

2. 核心数学模型

> (1) *DM* 估计器： $\hat{V}_{DM}(\pi_e) = \frac{1}{n}\sum_{i=1}^{n}\sum_{a\in A}\pi_e(a|x_i)\,\hat{q}(x_i,a)$
>
> (2) *IPS* 估计器： $\hat{V}_{IPS}(\pi_e) = \frac{1}{n}\sum_{i=1}^{n}[\pi_e(a_i|x_i)/\pi_b(a_i|x_i)]\cdot r_i$
>
> (3) *DR* 估计器： $\hat{V}_{DR}(\pi_e) = \frac{1}{n}\sum_{i=1}^{n}[\,\hat{q}(x_i,\pi_e) + (\pi_e(a_i|x_i)/\pi_b(a_i|x_i))\cdot(r_i-\hat{q}(x_i,a_i))\,]$

四、 技术路线与研究方法

项目分为数据基准构建、决策策略训练、OPE 估计计算及多维分析四个递进层次：

- **Step 1 数据流水线：** 提取 OBD 中用户上下文特征矩阵 X、推荐类目动作 A、点击回报 R 及原始日志中记录的行为倾向得分 π_b。
- **Step 2 策略设计与训练：** 训练 LinUCB、Logistic Thompson Sampling (LogisticTS) 以及基线 Random/Bernoulli 策略，输出条件动作分布 $\pi_e(a|x)$。
- **Step 3 绝对标尺对齐 (Ground Truth)：** 从纯随机 Bernoulli 策略日志中计算各新策略的在线无偏期望回报，作为评估标准。
- **Step 4 估计器综合评测：** 评估 DM、IPS、SNIPS、DR 等估计器的 MSE、方差表现及策略相对优劣的排序稳定性（Spearman 秩相关）。

五、 5 人小组成员分工与职责

角色与成员	核心职责 (Primary Tasks)	预期交付物 (Deliverables)	技能要求
组长 / 架构 成员 A	负责整体技术方案与架构设计，把控项目主线；统筹代码仓库规范与进度推进；主笔开题报告与答辩演讲结构设计。	项目开题报告、实验架构设计说明书、答辩串讲主稿	RL 基础、架构把控、答辩汇报
数据流水线 成员 B	负责 OpenBandit 数据集的下载、解析、切分与特征工程；清洗上下文特征与行为倾向得分；计算并输出全随机基线 Ground Truth。	高质量数据加载器 (Data Loader)、Ground Truth 基准计算脚本	Pandas、NumPy、数据特征工程
Bandit 策略算法 成员 C	负责 Contextual Bandit 策略开发与离线训练；实现 LinUCB、LogisticTS 算法，生成新策略的动作选择概率矩阵。	策略训练模块代码、策略动作分布输出文件 (.npy / .csv)	Scikit-learn、PyTorch、Bandit 算法

角色与成员	核心职责 (Primary Tasks)	预期交付物 (Deliverables)	技能要求
OPE 评估引擎 成员 D	负责实现与测试 DM、IPS、SNIPS、DR 等核心评估器；完成奖励预测回归模型的拟合与残差加权计算。	离线评估引擎模块、估计值统计与 MSE 计算自动化脚本	统计推断、回归建模、OPE 核心库
敏感度实验与可视化 成员 E	设计倾向得分截断（Clipping）敏感度测试；统计不同样本量下的偏差-方差折线图；制作高规格答辩 Poster 展板与图表资产。	偏差-方差实验分析报告、高质量 Matplotlib 图表、答辩 Poster	数据可视化、实验分析、海报美工排版

六、 进度安排与里程碑规划 (甘特周期)

阶段周期	主要任务与活动	阶段里程碑目标	主责成员
第 1 周 (启动期)	选题确立，开题报告定稿，文献调研与环境配置 (OBP, PyTorch)；数据采样子集探索。	**里程碑 1：**开题报告通过；完成环境搭建与 Mini 样本跑通 (MVP)。	全体成员 (成员 A/B 牵头)
第 2 周 (开发期)	全量/大类目数据流水线构建；实现 LinUCB 与 LogisticTS 策略训练并导出预测分布。	**里程碑 2：**成功训练 2 类 Contextual Bandit 策略并计算出 Ground Truth。	成员 B, 成员 C
第 3 周 (评测期)	部署 DM、IPS、SNIPS、DR 估计器并计算指标；开展倾向得分截断敏感度实验。	**里程碑 3：**产出全套评估器 MSE 对比表、方差柱状图及消融实验曲线。	成员 D, 成员 E
第 4 周 (交付期)	整理实验数据与消融结论；编写大作业终期技术报告；设计并排版 A4 学术演讲 Poster，演练现场 Q&A。	**里程碑 4：**完整实验代码仓归档、结题论文定稿、打印 Poster 并完成答辩演练。	全体成员 (成员 A/E 牵头)

七、 预期成果与创新特色

- **真实工业数据驱动：** 摆脱纯合成模拟环境（Synthetic Environments），基于真实千万级电商交互数据展开反事实推断验证。
- **理论与实操深度契合：** 直观印证统计学习中的“偏差-方差权衡（Bias-Variance Trade-off）”，验证 DR 方法在工业噪声下的鲁棒性。
- **高完成度工程规范：** 形成模块解耦的 Python 代码仓库（包含配置解耦、自动化评测脚本与规范文档），可直接作为高校/实验室可复现的 RL 实践模板。